

# Tópicos Especiais em Inteligência Computacional Aplicada a Segurança de Sistemas

## **Aula 07**

Programa de Pós-graduação em Computação Aplicada  
Núcleo de Desenvolvimento Amazônico em Engenharia  
Prof. Dr. Caio C. Moreira

# Ciclo de um sistema baseado em ML aplicado à segurança

- **Coleta de dados**
  - Logs, tráfego de rede, arquivos executáveis, eventos de execução.
  - Bases públicas de malwares (amostras brutas).
  - Bases Públicas com Características Extraídas (datasets prontos para ML)
- **Pré-processamento**
  - Limpeza e normalização dos dados.
  - Conversão de logs/arquivos em representações numéricas.
  - Tratamento de classes desbalanceadas (SMOTE, undersampling).
- **Extração de características (feature engineering)**
  - Permissões solicitadas por aplicativos.
  - Chamadas de API/sistema.
  - Frequência de pacotes em tráfego de rede.
  - Strings e entropia em executáveis.
- **Treinamento do modelo**
  - Escolha do tipo de algoritmo (supervisionado ou não supervisionado).
  - Escolha do modelo
  - Ajuste de hiperparâmetros.
- **Avaliação do modelo**
  - Divisão em treino/teste (ou validação cruzada).
  - Métricas: Acurácia, Precisão, Recall, F1-score, AUC-ROC.
- **Interpretação de resultados para validar a utilidade prática.**

# Interpretação de resultados

- Por que interpretar modelos?
  - Nem todo modelo com alta acurácia é realmente útil.
  - Precisamos compreender por que ele toma certas decisões — principalmente em contextos sensíveis (saúde, segurança, crédito, etc.).
  - Transparência e confiança no modelo.
  - Validação prática: as variáveis importantes fazem sentido?
  - Identificação de vieses e inconsistências.
  - Comunicação dos resultados para públicos não técnicos.
- Métodos de interpretação para ML são essenciais para compreender suas decisões.
- Eles podem identificar características-chave e detectar vieses ou inconsistências.
- Essas percepções aumentam a confiança nesses modelos para uma implementação bem-sucedida no mundo real.

# Interpretação de resultados

- Interpretação via Importância das Features (Modelos com suporte nativo)
  - Random Forest – Importância das Features
    - Calcula automaticamente a importância de cada variável com base na redução média da impureza (Gini ou Entropia).

```
# Modelo
model = RandomForestClassifier(n_estimators=100, random_state=42)
model.fit(X_train, y_train)

# Importância das features
importances = model.feature_importances_
df_importances = pd.DataFrame({
    'Feature': X_train.columns,
    'Importância': importances
}).sort_values(by='Importância', ascending=False)
```

# Interpretação de resultados

- Interpretação via Importância das Features (Modelos com suporte nativo)
  - Logistic Regression – Coeficientes interpretáveis
    - A Regressão Logística fornece coeficientes que indicam o peso e direção de cada variável na probabilidade de predição.

```
from sklearn.linear_model import LogisticRegression

logreg = LogisticRegression(max_iter=1000, random_state=42)
logreg.fit(X_train, y_train)

coef_df = pd.DataFrame({
    'Feature': X_train.columns,
    'Coeficiente': logreg.coef_[0]
}).sort_values(by='Coeficiente', ascending=False)
```

# Interpretação de resultados

- Interpretação via Importância das Features (Modelos com suporte nativo)
  - Outros modelos com interpretação nativa
    - DecisionTreeClassifier: `.feature_importances_`
    - XGBClassifier (XGBoost): `.feature_importances_` ou `plot_importance()`
    - LinearSVC: Coeficientes (`coef_`) após normalização
    - Lasso: Coeficientes não nulos indicam importância

# Interpretação de resultados

- Interpretação Avançada com SHAP
  - O SHAP (SHapley Additive exPlanations) é um método baseado na Teoria dos Jogos que **mede quanto cada feature contribui para uma predição específica.**
  - Permite entender tanto globalmente (modelo inteiro) quanto localmente (amostra individual) o comportamento do modelo.
  - Serve para todos os tipos de modelo.
    - Como um teste de caixa-preta

# Atividade 05

- 1) Treine o melhor modelo encontrado nas atividades passadas, com os melhores hiperparâmetros
- 2) Caso o modelo tenha o cálculo nativo da importância, apresente a lista das 30 melhores features e seus valores.
- 3) De qualquer forma, implemente o SHAP para gerar os gráficos de influência/importância abaixo:
  - a) Beeswarm
  - b) Decision Plot
- 4) Apresente os gráficos
- 5) Faça um texto (e incorpore no artigo) descrevendo cada gráfico.